

CANNBot开发进阶： PyPTO 算子开发实操

<https://gitcode.com/cann/cannbot-skills>

CANN

目录

Part 1 背景介绍

Part 2 Agent 架构

Part 3 案例实操

PyPTO 简介

PyPTO（发音: pai p-t-o）是一款面向AI加速器的高效编程框架，采用创新的**PTO（Parallel Tensor/Tile Operation）编程范式**，以基于Tile的编程模型为核心，通过多层次IR系统将高层Tensor图逐步编译为硬件可执行代码。

481

Stars

447

Forks

v0.2.0

最新版本

核心特性



基于 Tensor/Tile 的编程模型

充分利用硬件并行计算能力与内存层次结构



多层级计算图转换

Tensor → Tile → Block → Execution 逐步编译优化



自动化代码生成

编译结果自动生成底层指令，部署到目标平台



Python 友好 API

直观的Tensor级别抽象，支持动态Shape

目标用户



算法开发者

Tensor层次编程，快速实现验证算法



性能优化专家

支持开箱优化和深度性能调优



系统开发者

框架对接、工具链开发与集成

已适配大模型

DeepSeek 系列

GLM 系列

融合算子开发目标

CANNBot PyPTO 融合算子高效开发目标



降低开发周期

从编码、精度调试到性能调优，一周内全流程打通，提升迭代效率。



固化调优经验

Tiling 策略、流水配置、Loop 切分等关键调优环节形成标准化流程，不再依赖专家经验



降低上手难度

轻松调用 PyPTO 框架的功能与调优能力，降低使用门槛与学习成本



我们的解决方案

将专家经验固化为

7 个标准化 Skill

由

4 个专业 Agent

协同调度，构建端到端
自动化开发流程


目录

Part 1 背景介绍

Part 2 Agent 架构

Part 3 案例实操

CANNBot PyPTO 三层架构



4 个专业 Agent 协同工作

“Agent 编排 + Skill 执行” 分层架构 — 各司其职，协同完成全流程



编排师

pypto-op-orchestrator

全流程唯一 Owner

- 7 阶段状态机管理
- 工件门禁与重试控制
- 断点续跑与失败恢复
- 负责执行 Stage 1~2 和调度 3 个 SubAgent



分析师

pypto-op-analyst

分析型产物专家

- 生成 PyTorch 参考实现
- 输出完整设计文档
- 在隔离上下文中执行
- 负责执行 Stage 3~4



开发者

pypto-op-developer

实现与修复执行器

- 自动生成 Kernel 源码
- 三态判定与失败分类
- 代码检查与精度修复
- 负责执行 Stage 5~6



调优师

pypto-op-perf-tuner

性能迭代优化器

- 性能基线记录与分析
- Tiling / Loop / 流水搜索
- 精度优先的采纳策略
- 负责执行 Stage 7

7 阶段标准化开发流程

1 需求理解

2 API 探索

3 Golden 生成

4 方案设计

5 代码实现

6 精度调试

7 性能调优

1 需求理解

解析自然语言描述
提取 shape / dtype 约束

→ SPEC.md

2 API 探索

检索 PyPTO API 库
验证原语与组合可行性

→ API_REPORT.md

3 Golden 生成

PyTorch 参考实现
导出精度验证基准

→ {op}_golden.py

4 方案设计

API 映射和计算流设计
Tiling 策略 和 Loop 结构

→ DESIGN.md

5 代码实现

Kernel 源码生成
编译调试与运行

→ {op}_impl.py

6 精度调试

前端写法检查
精度对比定位

→ 精度修复

7 性能调优

多轮迭代优化
性能对比输出

→ 调优报告

流程详解 - 阶段1~2

1 需求理解

orchestrator 执行

解析自然语言中的公式 / shape / dtype 约束

提取计算逻辑与约束，标注置信度

生成结构化 SPEC.md（含数据流图）

2 API 探索

orchestrator 执行

将复合运算拆解为原子操作

检索 PyPTO API 库，验证组合可行性

输出 API_REPORT.md（含Tiling 建议）

Stage 1~2 由 orchestrator 直接调用 pypto-intent-understand 和 pypto-api-explore Skills

产出物

产出物目录

```
ops/{op}/  
├── SPEC.md      * Stage 1  
└── API_REPORT.md ← Stage 2
```

SPEC.md

算子名称: operation_name
数学公式: formula
算法描述: algorithm
数据规格: shape/dtype/dynamic_axis
精度标准: atol/rtol
性能要求: us
参考信息: 外部参考实现

API_REPORT.md

公式分解: operation
API映射: expr 到PyPTO API 映射
约束检查: API 约束
参考实现: models & examples 下的可参考的用例
可行性: 风险评估和是否可行

流程详解 - 阶段3~4

3 Golden 生成

analyst 执行

 基于 SPEC.md 生成纯 PyTorch 参考实现

 导出 {op}_golden() 标准函数签名

 生成精度验证基准数据集

4 方案设计

analyst 执行

 分析算子数据流模式与计算特征

 规划 Tiling 策略与 Loop 结构

 设计验证方案，输出 DESIGN.md

 Stage 3~4 由 pypto-op-analyst 在隔离上下文中执行，输出精度基准与设计方案

产出物

产出物目录

```
ops/ {op} /  
├── SPEC.md  
├── API_REPORT.md  
├── {op}_golden.py    * Stage 3  
└── DESIGN.md        * Stage 4
```

golden.py

```
def {op}_golden(x, scale):  
    y = x * scale  
    y = torch.round(y)  
    return torch.clamp(y, qmin, qmax) / scale
```

DESIGN.md

功能描述：算子功能描述
数学公式：数学公式描述
API 映射：公式到 PyTorch API 的映射关系
实现设计：计算流设计、推荐配置、Tiling策略、Loop结构
验证方案：测试用例设计和精度标准
交付件清单：交付件目录结构

流程详解 - 阶段5~6

5 代码实现

developer 执行



根据 DESIGN.md 自动生成 Kernel 源码



首跑前预检: golden 可导入 + 设计完整



三态判定: PASS / PRECISION_FAIL / 运行失败

6 精度调试

developer 执行



仅在 PRECISION_FAIL 时触发进入



排查前端写法问题



逐层精度对比定位问题算子



Stage 5~6 由 pypto-op-developer 执行, 从代码生成到精度收敛全程自动化

产出物

产出物目录

```
ops/{op} /
├── SPEC.md
├── API_REPORT.md
├── {op}_golden.py
├── DESIGN.md
├── {op}_impl.py      * Stage 5
└── test_{op}.py     * Stage 5
```

{op}_impl.py 核心结构

```
@pypto.frontend.jit
def qat_forward(x, scale):
    # 1. view
    # 2. calc
    # 3. assemble
```

test_{op}.py

```
x = gen_random_data(shape)
y_npu = impl.{op}_forward(x, scale)
y_cpu = golden.{op}_forward(x, scale)
assert_allclose(y_npu, y_cpu, atol, rtol)
```

流程详解 - 阶段7

7 性能调优

perf-tuner 执行



记录 Kernel 基线耗时、shape、精度指标



搜索 Tiling 参数、Loop 切分、流水配置



每轮：分析→调优→复验→采纳/回滚



达到最大调优轮次或连续多轮无性能提升后终止

README.md

算子概述：算子名称和描述

算子公式：formula

算子规格：shape/dtype等

目录结构：算子目录结构

运行方式：cd custom/{op} && python test_{op}.py

完整产出物

产出物目录

```
ops/{op} /
├── SPEC.md
├── API_REPORT.md
├── golden.py
├── DESIGN.md
├── IMPL.py
├── TEST_{OP}.py
├── PERF_REPORT.md * Stage 7
└── README.md
```

PERF_REPORT.md

调优性能：提升 5 倍实

际提升：提升 5.9 倍调

优时长：73 分钟

迭代轮次：6

调优策略：Tiling、loop_unroll



Stage 7 由 pypto-op-perf-tuner 执行，精度通过后自动进入性能迭代优化

目录

Part 1 背景介绍

Part 2 Agent 架构

Part 3 案例实操

环境准备

环境要求

依赖	版本要求
昇腾硬件	Atlas A2 / A3 推理或训练系列
CANN	≥8.0
Python / PyTorch	≥3.9 / ≥2.6

支持平台

- OpenCode（默认）
- Claude Code

>_ CANNBot 部署

```
$ git clone https://gitcode.com/cann/skills.git
$ cd skills/teams/pyto-op-orchestrator
$ bash init.sh project opencode
```

>_ 打开 opencode

```
$ opencode
```

💡 示例1(交互式需求澄清)：“我想开发一个融合算子”

我想开发一个融合算子

Thinking: The user wants to develop a fusion operator. This is a PyTorch operator development request, and I need to follow the orchestrator workflow. However, the user's description is quite vague - "融合算子" (fusion operator) is very generic. I need to understand what specific fusion operator they want to develop.

Let me follow the startup flow:

1. Parse operator name and working directory
2. Check if .orchestrator_state.json exists
3. If not, initialize state

But first, I need to understand what the user actually wants. The term "融合算子" could mean many things - it could be a fusion of multiple operations, or a specific fusion operation. I should ask the user for more details before proceeding with Stage 1 (intent understanding).

Actually, looking at the orchestrator instructions, Stage 1 is "需求理解" (intent understanding) which uses the pytorch-intent-understand skill. But the user hasn't given me enough information yet. Let me ask for more details about what kind of fusion operator they want to develop.

Wait, I should think about this more carefully. The user said "我想开发一个融合算子" which is quite vague. I need to ask them what specific operator they want - what operations to fuse, what the input/output tensors look like, etc.

Let me ask the user for clarification.

您好！您提到想开发一个“融合算子”，但这个描述比较宽泛。为了准确地启动开发流程，我需要了解更多细节。

请补充以下信息，帮助我理解您的需求：

1. 算子名称/类型：具体是哪种融合算子？例如：
 - LayerNorm + MatMul 融合
 - Softmax + MatMul 融合（如 Flash Attention 风格）
 - Bias + Add + Activation 融合（如 BiasAddGelu）
 - 其他特定操作的组合
2. 输入输出：涉及哪些 Tensor，各自的 dtype 和 shape 是怎样的？
3. 参考来源：是否有参考的 PyTorch API（如 F.scaled_dot_product_attention）、论文公式、或已有的算子规格？
4. 精度要求：是否需要与 PyTorch float32 结果做精度对比？
5. 性能目标：是否有特定的性能指标要求？

有了这些信息，我就可以启动 Stage 1（需求理解），为您生成结构化的 SPEC.md 并进入后续开发流程。

■ Pytorch-Op-Orchestrator - GLM-5-Turbo - 18.1s

快速上手

💡 示例2(常见算子开发)：“开发一个 softmax 算子”

开发一个softmax算子

Thinking: 用户要求开发一个 softmax 算子。作为 pypto-op-orchestrator, 我需要按照启动流程来执行。

1. 解析算子名 {op} 与工作目录 custom/{op}/
2. 检查 custom/{op}/orchestrator_state.json 是否存在
3. 若不存在状态文件, 先通过 state_transition 初始化状态
4. 遍历当前目录下已存在的工件
5. 从 current_stage 开始循序渐进

算子名是 softmax, 工作目录是 custom/softmax/.

让我先检查目录和状态文件是否存在。

我来启动 softmax 算子的端到端开发流程。首先进行启动前的环境检查。

```
<< ls [path=/workspace/projects/code/pypto/custom]
$ ls /workspace/projects/code/pypto/custom/softmax/ 2>/dev/null || echo "DIR_NOT_EXISTS"
```

算子目录 custom/softmax/ 不存在, 这是新算子开发场景, 现在创建目录并初始化状态机。

```
<< mkdir [path=/workspace/projects/code/pypto/custom/softmax]
<< state_transition [opDir=custom/softmax, action=start_stage, stage=1]
```

状态机已初始化, Stage 1 开始。现在加载 pypto-intent-understand Skill 执行需求理解。

Todos

- [*] Stage 1: 需求理解 - 调用 pypto-intent-understand 生成 SPEC.md
- [] Stage 2: API 探索 - 调用 pypto-api-explore 生成 API_REPORT.md
- [] Stage 3: Golden 生成 - 调度 pypto-op-analyst 生成 softmax_golden.py
- [] Stage 4: Design 设计 - 调度 pypto-op-analyst 生成 DESIGN.md
- [] Stage 5: 代码实现 - 调度 pypto-op-developer 生成 impl/test
- [] Stage 6: 精度验证 (需要)
- [] Stage 7: 性能调优

* Skill "pypto-intent-understand"

💡 示例3(自定义算子开发)：“读取 requirement.md，根据需求开发自定义算子”

读取 requirement.txt，根据需求开发自定义算子（开发前打印原始需求）

Thinking: The user wants me to read a requirement.txt file and then develop a custom operator based on the requirements. Let me first find and read the requirement.txt file.

```
# Glob **/requirement*.txt"
# Glob **/requirement.txt"
# Glob **/Requirement*.txt"
$ find /workspace/projects/code/gypto -maxdepth 1 -iname "requirement*" -o -iname "需求*" 2>/dev/null | head -20
```

找到了 requirement.md，让我读取它。

- Reading file...

好的，以下是原始需求：

 原始需求

算子名称： custom_add_norm

公式： $y = \frac{x_1 + x_2}{\sqrt{\sigma^2 + \epsilon}} \cdot \gamma + \beta$

- μ 和 σ^2 分别是 x_1+x_2 在最后一个维度上的均值和方差（沿 hidden_size 维度）
- $\epsilon = 1e-5$
- γ 和 β 为可学习参数，形状与最后一个维度一致

规格：

类型	shape	dtype
输入 x1	[*, hidden_size]	bfloat16
输入 x2	[*, hidden_size]	bfloat16
输入 gamma	[hidden_size]	bfloat16
输入 beta	[hidden_size]	bfloat16
输出 y	[*, hidden_size]	bfloat16

精度标准： atol=0.0001, rtol=0.0078125

特殊要求： batch 维度（* 部分）是动态轴

现在开始按编译流程启动算子开发。首先检查状态文件和现有工件。



CANNBot PyPTO — 让融合算子开发变得简单

CANNBot PyPTO通过Agent驱动的方式，
将复杂的算子开发流程化繁为简。
从需求描述到算子运行，全流程自动化：
设计方案、编写代码、调试调优。

现在，开始您的**CANNBot PyPTO**之旅！

欢迎关注、使用、贡献，共建社区！

<https://gitcode.com/cann/pypto> &
<https://gitcode.com/cann/skills>

CANNBot Skills开源交流群

点击如下链接获取

<https://gitcode.com/cann/cannbot-skills/discussions/2>

Thank you.

社区愿景：打造开放易用、技术领先的AI算力新生态

社区使命：使能开发者基于CANN社区自主研究创新，构筑根深叶茂、跨产业协同共享共赢的CANN生态

Vision: Building an Open, Easy-to-Use, and Technology-leading AI Computing Ecosystem

Mission: Enable developers to independently research and innovate based on the CANN community and build a win-win CANN ecosystem with deep roots and cross-industry collaboration and sharing.



上CANN社区获取干货



关注CANN公众号获取资讯