


CANN 开源推理仓库 概览与实践入门

昇腾 CANN 启航营
从仓库结构到模型运行



目录

01

从理论到工程实践

将大模型推理基础概念映射到工程实现

03

模型推理优化案例

主流开源模型在 CANN 上的推理优化实践

05

社区参与与实践路径

加入 cann-recipes-infer 开源社区

02

生态概览

cann-recipes-infer 开源推理生态全景

04

Agent 自动化优化

AI 驱动的自动化推理优化流程




01 从理论到工程实践

回顾推理基础概念

推理核心概念回顾

回顾第一课核心概念，建立从理论到工程的认知桥梁



Prefill 阶段

- 一次性处理完整输入中的所有 token
- 计算密集型：矩阵乘法为主
- 决定 TTFT（首 token 延迟）
- 同时计算并缓存 KV

Decode 阶段

- 逐 token 生成，循环执行
- 访存密集型：需读取 KV Cache
- 决定 TPOT / TPS
- 每步生成后追加到上下文

KV Cache

- 缓存历史 token 的 K/V
- 用显存换取计算速度
- 长文本生成的必要优化
- 上下文越长，cache 越大



本节课目标：观察上述概念在 `cann-recipes-infer` 仓库中的工程体现，理解理论如何指导实践。

Prefill、Decode 和 KV Cache 是大模型推理的三个核心环节，本节课将展示它们在工程中的具体实现。

推理性能指标解读


理解 TTFT、TPOT、TPS 三个核心指标的含义与工程意义

TTFT
Time To First Token
用户发送请求到收到第一个 token 的时间
主要由 **Prefill** 阶段决定
反映用户感知的 " 响应速度 "

TPOT
Time Per Output Token
相邻两个输出 token 之间的平均间隔
主要由 **Decode** 阶段决定
反映用户感知的 " 打字速度 "

TPS
Tokens Per Second
单位时间内生成的 token 数量
综合指标，与并发数相关
反映系统整体吞吐能力

生成时间线示意



三个指标分别衡量首 token 等待、持续生成速度和系统吞吐能力，是评估推理性能的关键依据。本节课展示的性能数据均基于这些指标。

TTFT、TPOT、TPS 是评估推理系统性能的三个核心指标，后续案例中的性能数据均基于这些指标。

02 生态概览

cann-recipes-infer 开源推理生态全景



cann-recipes-infer 开源推理生态

一站式开源大模型推理仓库，覆盖 **20+ 主流模型**，持续迭代

727

Stars

105

贡献者

20+

模型覆盖

6

模型方向

仓库定位

cann-recipes-infer 是面向昇腾 Atlas 平台的一站式开源大模型推理仓库，集模型适配、性能优化、量化压缩、多模态支持于一体。仓库覆盖当前主流的开源大语言模型、MoE 架构模型、长文本模型和多模态模型，持续跟进最新模型发布并提供 CANN 适配方案。

核心能力



模型适配

Dense / MoE / 多模态



性能优化

量化 / 融合算子 / 图模式



Agent 自动化

一键优化 / 全流程覆盖



完善文档

接入指南 / 性能报告

仓库持续更新，新模型和优化策略不断加入。gitcode.com/cann/cann-recipes-infer

仓库结构导览

cann-recipes-infer 采用 "模型即目录" 的组织方式, 每个模型独立维护

仓库目录结构

cann-recipes-infer/

- |—— **models/** 模型脚本 (核心, 20+ 模型)
 - | |—— deepseek_v4/ 通用 LLM
 - | |—— qwen/ ← 下节课实践
 - | |—— qwen3_moe/ MoE 架构
 - | |—— ... glm_5, longcat_flash 等
- |—— **executor/** 执行器框架
- |—— **accelerator/** 加速组件
- |—— **docs/** 技术文档
- |—— **ops/** 自定义算子
- |—— **module/** 基础模块与量化
- |—— **dataset/** 数据集
- |—— **scripts/** 环境脚本 + AGENTS.md
- |—— README.md

models/ 目录

每个模型一个独立目录, 包含 model 文件、推理脚本、配置文件和 README。这是仓库的核心部分。

docs/ 目录

按模型组织的技术文档, 包含接入指南、性能调优手册和优化案例说明。降低模型接入门槛。

executor/ 目录

推理执行框架, 含核心模块、权重加载、离线 / 在线推理入口、调度器等。统一入口 infer.sh 位于此。

ops/ 目录

自定义算子目录, 含 AscendC 算子和 PyPTO 算子。

仓库采用 "模型即目录" 的组织方式, 每个模型目录包含完整的推理配置和运行脚本。

推理流程与代码映射

理论中的每个环节，在仓库中都有对应的工程实现

理论环节	工程对应	仓库中的具体位置
Prefill	一次性处理完整输入，执行前向计算，生成首 token 并缓存 KV	executor/scripts/infer.sh 调用 GE 图编译，执行前向计算
Decode	循环调用 forward，每轮生成一个新 token，直到触发结束条件	models/<model>/models/ 模型脚本与 forward 调用逻辑
KV Cache	缓存历史 token 的 K/V 张量，Decode 阶段直接读取复用	executor/ 框架层 KV Cache 管理与缓存策略
性能观测	测量 TTFT、TPOT、TPS 等指标，分析推理瓶颈	运行日志输出 推理结果与性能指标记录

理解这一映射关系后，阅读仓库源码时即可定位到每个推理环节的具体实现，为后续调试和优化奠定基础。

理论中的每个环节，在仓库中都有对应的工程实现。



cann-recipes-infer 模型覆盖

覆盖 20+ 主流模型，持续跟进最新模型发布与 CANN 适配

方向	代表模型	技术特点
通用 LLM	qwen, openpangu 等	Dense 架构、文本对话
MoE 架构	deepseek_r1, qwen3_moe 等	稀疏专家激活、降低推理成本
长文本	longcat_flash, longcat_flash_lite 等	长序列处理、高效上下文推理
多模态	hunyuan-video, sana-video, hunyuan-image-3.0 等	视频 / 图像生成、多模态理解

技术方向说明

通用 LLM：Dense 架构，文本对话

MoE 架构：稀疏激活，降低推理成本

长文本：超长上下文处理

多模态：视频 / 图像生成

cann-recipes-infer 覆盖当前主流模型架构和任务类型，新模型持续加入。



技术文档与社区资源

完善的文档体系降低模型接入门槛

文档体系

README（快速入门）

根目录 README 含快速开始指南，各模型目录下 README 含具体推理步骤。

docs/（技术文档）

含 models、cann、agent、design、integration 等子目录的深度技术文档。

AGENTS.md / CONTRIBUTION.md

Agent 能力说明与社区贡献指南，含协作流程和代码规范。

社区渠道

 **GitCode 仓库**
代码、Issue、PR 协作平台

 **技术博客**
优化案例、技术解析、最佳实践

 **讨论区**
问题答疑、经验交流、方案讨论

完善的文档体系与活跃的社区，是降低模型接入门槛、推动生态发展的重要支撑。



03 模型推理优化案例

主流开源模型在 CANN 上的推理优化实践

DeepSeek-V4 模型概览

DeepSeek-V4 提供双版本架构，分别面向不同应用场景

DeepSeek

深度求索旗下开源大模型，以高性价比推理著称

Flash

284B 参数规模
1M 长序列支持
面向长文本、高效推理场景
Hybrid Attention 机制

Pro

1.6T 参数规模
MoE 混合专家架构
面向复杂任务、高性能场景
Expert Parallel 并行策略

cann-recipes-infer 支持状态

✓ DeepSeek-R1

推理模型，已完整支持

🧪 DeepSeek-V3.2

实验版本，含 TileLang 算子

✓ DeepSeek-V4

最新版本，双版本均已支持

📖 技术文档

7 篇专项技术指南

DeepSeek 系列在 cann-recipes-infer 中保持高频更新，可直接在昇腾 Atlas 上运行。



DeepSeek-V4 性能亮点

昇腾 950DT 平台实测，**单请求时延低于 10ms**

Flash

< 10 ms

单请求时延 (TPOT)

Flash

4722 TPS

多并发吞吐 @20.15ms

Pro

20 ms

单请求时延 (TPOT)

Pro

388 TPS

多并发吞吐 @21ms

长序列处理能力

128K 长序列

Prefill 时延 < 1s

1M 长序列

Prefill 时延 < 5s

128K 序列 Decode

TPOT 仅 7.8ms，长序列下时延无明显衰减

核心技术支撑

Hybrid Attention

滑窗 + 稀疏 + 压缩三种机制交织，降低长序列计算复杂度

FP8 / MXFP8 量化

原生 FP8 + MXFP4 量化，MXFP8-MXFP4 组合性能最优

MoE Expert Parallel

Attention DP + MoE EP 混合并行，降低单卡计算量

数据来自昇腾 950DT 实测，MXFP8-MXFP4 量化。



Qwen 系列模型概览与技术亮点

CANN 社区已支持 Qwen 系列多个版本，覆盖 Dense 和 MoE 架构

Qwen 阿里云开源大模型系列	Qwen3 基础 Dense 架构版本	Qwen3-MoE 混合专家架构，动态激活专家网络
	Qwen3-Next 下一代架构探索，接入融合算子	Qwen3.5 升级版本，综合性能提升

技术亮点

 多版本覆盖 同时维护 Qwen3 、 Qwen3.5 、 Qwen3-MoE 、 Qwen3-Next 四个版本 Dense 和 MoE 架构均已支持	 融合算子优化 Qwen3-Next 接入 RMSNormGated 、 GDR 融合算子 减少 kernel 调度开销
---	---

技术优化路线

基础适配 → 融合算子 → 多版本覆盖，形成对 Dense 和 MoE 架构的全面支持。

Qwen 系列在 cann-recipes-infer 中保持高频更新，融合算子与多版本覆盖持续完善。



更多案例速览： GLM-5 与 LongCat-Flash

不同架构的模型均能在 CANN 上获得显著性能提升

GLM-5

智谱 AI 开源模型

22.54
ms TPOT

177
TPS

64
卡 A3 集群

- 支持 W8A8 和 mxfp8 量化
- 已在 Atlas A3 和 950 平台完成验证
- 64 卡 A3 / W8A8 / Batch=256 / Seq=64K

LongCat-Flash-Lite

美团开源长文本模型

5.76
ms 最低 TPOT

1124
TPS 最高吞吐

1.38x
综合性能提升

- 69B 参数 MLA + Sparse MoE
- Decode 时延降低 27%
- 低精度量化 + 多流并行 + 融合算子

关键优化手段

低精度量化
W8A8 / FP8 / MXFP8

多流并行
Multi-Stream Overlap

融合算子
减少调度开销

图模式
GE 图编译优化

不同架构的模型均能在 CANN 上获得显著性能提升。

<https://gitcode.com/cann>

16

多模态推理支持

CANN 推理能力超越文本，覆盖视频生成、图像生成等多模态任务

**HunyuanVideo**
腾讯混元视频生成模型
支持文本到视频生成

**HunyuanImage 3.0**
腾讯混元图像生成模型
支持文本到图像生成

**Sana-Video**
高效视频合成模型
支持高分辨率视频生成

**Wan2.2-I2V**
图生视频模型
支持图像到视频转换

多模态推理是 CANN 生态的重要拓展方向。上述模型均已接入 cann-recipes-infer 仓库，覆盖视频生成、图像生成等主流多模态任务类型。

多模态推理是 CANN 生态的重要拓展方向，模型覆盖持续扩大。



04 Agent 自动化优化

AI 驱动的自动化推理优化流程

Agent workflows与优化 Skill

输入自然语言指令，自动完成全流程推理优化


Agent 能力：输入自然语言指令（如 "帮我优化 Qwen3-8B 模型"），Agent 自动完成 **架构分析 → 方案设计 → 代码改造 → 精度验证 → 性能报告** 的全流程。

典型 workflow



每个阶段均设置验证门禁，未通过则自动回退迭代，确保优化质量。

7 大优化 Skill



Agent 能力已内置在 cann-recipes-infer 仓库中，跟随仓库一起更新。

<https://gitcode.com/cann>



使用入口与已验证案例

Agent 能力持续迭代，覆盖推理仓和 CANNBot 插件

两种使用入口



仓库内置

Skill / Agent / Hook 已内置

`bash scripts/init-agent.sh` 一键部署



CANNBot 插件

支持 Claude Code / OpenCode / TRAE / Cursor

IDE 内直接调用 Agent 能力

已验证案例

LongCat-Flash-Lite

Agent 自动完成模型迁移

Decode 时延降低 **27%**

覆盖量化、并行、融合算子优化

Gemma-4

多卡并行 + 融合算子 + 量化

完整优化闭环

从方案设计到性能验证全覆盖

Hunyuan-3

图模式 + KVCache 优化

大规模模型稳定部署

验证了 Agent 处理复杂模型的能力

Agent 能力持续迭代，覆盖推理仓和 CANNBot 插件。[cann-recipes-infer](#)（推理仓） & [cannbot-skills](#)（CANNBot 插件）

05

社区参与与实践路径

加入 cann-recipes-infer 开源社区

参与社区贡献

多种参与方式，无论代码贡献还是文档改进，每一份参与都在推动生态成长

**Star & Fork**

收藏仓库表示支持
Fork 到个人账号
基于个人 Fork 进行开发和实验
关注仓库动态获取更新

**提交 PR**

修复 bug
优化现有模型性能
新增模型支持
社区审核后合并入主分支

**完善文档**

补充使用教程
撰写性能调优指南
翻译技术文档
分享实践经验和踩坑记录

社区资源

**GitCode**
代码仓库

**技术文档**
接入与调优

**讨论区**
答疑交流

**示例代码**
实践参考


**性能数据**
README / docs

无论代码贡献还是文档改进，每一份参与都在推动 CANN 生态成长。



从 0 到 1 运行一个模型

掌握四步流程，即可在 CANN 上运行任何支持的模型



以 Qwen3-8B 为例


`models/qwen/` → 阅读 README 了解推理配置 → 执行 `bash executor/scripts/infer.sh --model qwen` → 阅读运行日志，分析 TTFT / TPOT / TPS。

掌握这四步，即可在 CANN 上运行任何支持的模型。

学习路径与资源汇总

理论指导实践，实践验证理论，持续迭代优化能力

推荐学习路径



关键资源

资源类型	说明与链接
仓库	gitcode.com/cann/cann-recipes-infer — 代码、文档、Issue
技术文档	仓库 docs/ 目录下的模型接入指南和性能调优手册
社区	CANN 社区主页 — 训练营课程、技术博客、讨论区
课程	昇腾 CANN 训练营 — 系统化学习 CANN 推理优化

理论指导实践，实践验证理论，持续迭代优化能力。



Qwen3-8B：后续实践入口



Qwen3-8B 是后续 **Notebook 推理实践课程**的指定模型。本节课了解其在 CANN 上的支持状态，为后续动手实践建立认知基础。

仓库中的位置与配置

模型目录

[models/qwen/](#)

推理配置

qwen3_8b_1tp.yaml

部署方式

单卡推理

实践目标

配置环境 → 加载模型 → 运行推理

课前准备



熟悉本节课的仓库结构
和推理流程概念



用 GitCode 账号
Star/Fork cann-recipes-infer



确认 GitCode Notebook
环境情况

下节课将基于 Qwen3-8B 进行 Notebook 推理实践。



Qwen3-8B 文件结构详解

models/qwen/ 目录组织与关键文件说明

models/qwen/ 目录结构

```
models/qwen/  
├── config/ 推理配置  
│   ├── qwen3_8b_1tp.yaml ← 基础推理配置  
│   └── ...  
├── models/ 推理代码  
│   ├── configuration_qwen.py  
│   └── modeling_qwen.py ← 推理核心代码  
├── README.md 使用文档  
└── requirements.txt 依赖文件
```

config/ — 推理配置

YAML 配置文件定义模型路径和推理参数。qwen3_8b_1tp.yaml 是基础推理配置，指定模型文件路径、推理后端等参数，通过 --yaml 参数启动时加载。

models/ — 模型脚本

configuration_qwen.py 定义模型配置类，modeling_qwen.py 实现模型结构与前向计算。Qwen3-8B 与 Qwen2.5-7B-Instruct 共用同一套建模代码，通过 config.json 自动识别模型变体。

启动方式

统一走 executor/scripts/infer.sh 入口，通过 --model qwen --yaml config/qwen3_8b_1tp.yaml 指定。README.md 含完整的环境准备、权重下载和推理步骤。

config/ 定义推理参数， models/ 实现模型核心逻辑，两者配合完成 Qwen3-8B 在 CANN 上的单卡推理。



Thank you.

开启你的 CANN 推理之旅

gitcode.com/cann/cann-recipes-infer

社区愿景：打造开放易用、技术领先的 AI 算力新生态

社区使命：使能开发者基于 CANN 社区自主研究创新，构筑根深叶茂、跨产业协同共享共赢的 CANN 生态



上 CANN 社区获取干货



关注 CANN 公众号获取资讯